DetiBuddy - Decisoes de Arquitetura (ADRs)

Engenharia de Software - Fase de Elaboracao (Milestone 2)

Resumo Executivo da Arquitetura v2

A arquitetura do **DetiBuddy** foi consolidada e validada durante a Fase de Elaboracao (Milestone 2), evoluindo da visao preliminar da *Inception* para a **Arquitetura v2**, uma topologia modular, assincrona e desacoplada baseada em microsservicos e no protocolo **MCP (*Model Context Protocol*)**.
O sistema esta confinado a infraestrutura soberana da Universidade de Aveiro (servidores DETI e cluster Skynet), garantindo conformidade rigorosa com o RGPD e total soberania dos dados dos estudantes e da comunidade academica.

ADR-01: Topologia de Borda e Cliente Web (Traefik + React PWA)

Estado:** Aprovado
Contexto:** Os estudantes acedem ao assistente atraves de smartphones, computadores portateis e tablets tanto na rede do campus como no exterior.
Decisao:** Adocao do proxy reverso de borda **Traefik** e de uma aplicacao web progressiva **React PWA** (*Progressive Web App*).
Justificacao:**

* Permite instalacao direta no ecra inicial do smartphone sem friccao de lojas de aplicacoes.
* Suporte nativo a modos claro/escuro (*Dark/Light Mode*) e design responsivo fluido.
* O Traefik gere terminacao TLS/SSL, encaminhamento de rotas por subdominio e *rate limiting* preventivo.

Consequencias:** A aplicacao nativa Android passa a requisito de expansao (*Could Have*), garantindo cobertura universal no MVP atraves da web movel.

ADR-02: Backend Assincrono com Server-Sent Events (FastAPI + SSE)

Estado:** Aprovado
Contexto:** Assistentes baseados em LLM geram texto token a token. O tempo ate a primeira resposta (*Time To First Token - TTFT*) e critico para a experiencia conversacional.
Decisao:** Desenvolvimento do backend em Python utilizando a framework assincrona **FastAPI** com streaming de respostas via **SSE (*Server-Sent Events*)**.
Justificacao:**

* O SSE opera sobre HTTP standard, contorna firewalls institucionais sem bloqueios de WebSockets e suporta reconexao automatica nativa no browser.
* O FastAPI assegura tipagem estrita com Pydantic v2 e alto desempenho em I/O assincrono.

Consequencias:** Menor overhead operacional do que sockets bidirecionais permanentes, com streaming fluido das respostas do LLM.

ADR-03: Desacoplamento de Servicos Externos via Model Context Protocol (MCP)

Estado:** Aprovado
Contexto:** O DetiBuddy integra multiplos sistemas universitarios (PACO, Moodle, SAS, M365, IPMA, Parques, Bibliotecas). Alguns dependem de autorizacao dos STIC e outros disponibilizam APIs abertas.
Decisao:** Cada dominio funcional e isolado no seu proprio **Servidor MCP dedicado**, comutavel via variavel de ambiente entre ‘mock‘, ‘real‘ e ‘scraper‘.
Justificacao:**

* O MCP padroniza as *tool calls* do agente de IA atraves de esquemas JSON-RPC estruturados.
* Permite testar o sistema de ponta a ponta com mocks realistas enquanto decorrem as aprovacoes institucionais de seguranca (Planos de Contingencia A, B e C).

Consequencias:** Qualquer alteracao na API de um servico externo afeta apenas o respetivo servidor MCP, sem impacto no nucleo conversacional do agente.

ADR-04: Autenticacao Institucional e IdP Simulado (Keycloak OIDC)

Estado:** Aprovado
Contexto:** A autenticacao final requer integracao com o IdP dos STIC (OpenID Connect / SAML). Durante o desenvolvimento, a equipa necessita de testar fluxos com multiplos perfis de estudante e docente.

Decisao:** Incorporacao de uma instancia Docker do **Keycloak** a replicar o IdP institucional da UA em modo OIDC.

Justificacao:**

* Permite emitir tokens JWT com os mesmos *claims* (NMEC, perfil, curso) e testar a politica de acessos RBAC sem depender de credenciais reais dos STIC.

Consequencias:** A transicao para o IdP de producao exige apenas a alteracao dos endpoints de autorizacao e chaves publicas no '.env'.

ADR-05: Persistencia Hibrida e Base de Dados Vetorial (PostgreSQL + pgvector)

Estado:** Aprovado

Contexto:** O sistema necessita de armazenar dados relacionais (sessoes, utilizadores, historico efemero de conversas) e realizar pesquisa semantica em regulamentos pedagogicos e bibliografia.

Decisao:** Unificacao da persistencia em **PostgreSQL** com a extensao **pgvector**.

Justificacao:**

* Evita a complexidade operacional e risco de desfasamento de manter uma base relacional e uma base vetorial dedicada (como Qdrant ou Pinecone) em contentores separados.
* Suporta **Busca Hibrida** combinando similaridade densa de embeddings vetoriais com pesquisa lexica BM25 / trigramas para codigos de UC e nomes de docentes.

Consequencias:** Simplificacao arquitetural, integridade transacional ACID estrita e backups unificados num unico volume persistente.

ADR-06: Cache, Filas de Mensagens e Workers Assincronos (Redis + ARQ)

Estado:** Aprovado

Contexto:** Consulta frequente de ementas, estado de ocupacao de parques e processamento pesado de indexacao de PDFs regulamentares e envio de notificacoes push.

Decisao:** Adocao de **Redis** em memoria associado a um worker assincrono **ARQ**.

Justificacao:**

* Implementacao de estrategia *quickload* com TTL (cache de curta duracao para parques e ementas).
* O worker ARQ descarrega o processo principal da API durante o chunking e embedding de regulamentos e no despacho de notificacoes.

Consequencias:** Reducao drastica da latencia para chamadas repetidas e resposta instantanea para utilizadores concorrentes.

ADR-07: Inferencia Soberana de LLM (Cluster Skynet do DETI)

Estado:** Aprovado

Contexto:** Protecao de dados pessoais e regulamentacao europeia (RGPD) no tratamento de conversas e dados academicos de estudantes universitarios.

Decisao:** O modelo de linguagem (LLM) corre localmente no cluster de servidores **Skynet** do Departamento de Eletronica, Telecomunicacoes e Informatica (DETI).

Justificacao:**

* Garantia absoluta de que nenhuma mensagem, duvida academica ou dado de contexto transita para servidores de clouds comerciais (OpenAI, Anthropic ou Google).
* API de inferencia de alta velocidade compativel com o padrao OpenAI via rede interna segura.

Consequencias:** Soberania tecnica completa e custos de operacao nulos em subscricoes externas de APIs proprietarias.

ADR-08: Alinhamento de Ambito e Gestao de Riscos (Elaboracao vs. Inception)

Estado:** Aprovado

Contexto:** Na fase de Inception foram identificadas ideias alargadas, incluindo consulta de saldo de cartoes bancarios SAS e pagamento de propinas.

Decisao:** Exclusao fundamentada de transacoes bancarias e saldos monetarios do ambito do projeto (*Won't Have*).

Justificacao:**

* Operacoes financeiras acarretam requisitos de certificacao bancaria (PCI-DSS) e autorizacoes institucionais complexas que inviabilizariam o cronograma semestral de PEI.
* Foco prioritario na agregacao pedagogica, RAG de regulamentos, horarios, avaliacoes e servicos de campus.

Consequencias:** Reducao de riscos criticos e garantia de entrega de um MVP robusto, funcional

e perfeitamente testavel.